



**ANÁLISIS COMPARATIVO DE MODELOS DE APRENDIZAJE AUTOMÁTICO PARA LA
PREDICCIÓN DE MERCADOS FINANCIEROS**

MODALIDAD DEL TFG: CONVENCIONAL

CONVOCATORIA: Abril

ALUMNO / A: Petr Podlesskii

TUTOR / A: Stanislav Vakaruk Vakaruk

GRADO: Ingeniería del Software

ÍNDICE

ABSTRACT	4
1. INTRODUCCIÓN	5
1.1. Motivación y contexto	5
1.2. Planteamiento del problema.....	6
1.2.1. Descripción técnica del problema	6
1.2.2. Desafíos específicos	6
1.2.3. Alcance del problema	7
1.3. Objetivos del trabajo	7
1.3.1. Objetivo principal	8
1.3.2. Objetivos Específicos.....	8
2. MARCO TEÓRICO Y ESTADO DEL ARTE	9
2.1. Aprendizaje Automático en Mercados Financieros	9
2.2. Modelos de Aprendizaje Automático	10
2.2.1. Modelos lineales	11
2.2.2. Árboles de decisión.....	12
2.2.3. Regresión XG-Boost.....	13
2.2.4. Redes neuronales recurrentes.....	14
2.2.5. Redes neuronales convolucionales	15
2.3. Trabajos relacionados	17
3. ASPECTOS METODOLÓGICOS	18
3.1. Metodología general del trabajo	18
3.1.1. Fase de Investigación.....	18
3.1.2. Fase de Implementación	18
3.1.3. Fase de Evaluación	19
3.2. Búsqueda y recogida de datos.....	20
3.2.1. Selección de tickers.....	20
3.2.2. Selección del período temporal.....	21
3.2.3. Selección de targets para predicción.....	21
3.3. Investigación de features.....	22
3.3.1. YFinance features	22
3.3.2. Features derivados de precios	23

3.3.3. Indicadores económicos adicionales	24
3.3.4. Estructura final de datos.....	26
3.4. Tecnologías empleadas	27
4. DESARROLLO DEL TRABAJO	28
4.1. Implementación del Sistema	28
4.1.1. Procesamiento de datos por tipo de modelo	29
4.1.2. Arquitectura base para los modelos	30
4.1.3. Implementación de los modelos específicos	31
4.1.4. Sistema de evaluación y métricas	32
4.2. Análisis de Resultados	32
4.2.1. Modelos de regresión.....	32
4.2.2. Modelos de clasificación.....	39
5. CONCLUSIONES	49
5.1. Desarrollo del Trabajo Realizado	49
5.2. Resultados Principales	50
5.3. Perspectivas Futuras.....	50
6. REFERENCIAS.....	52
6.1. Bibliografía	52
6.2. Índice de figures.....	54
7. ANEXOS.....	55

RESUMEN

Este trabajo estudia la eficacia de varios enfoques de aprendizaje automático y aprendizaje profundo para predecir el comportamiento del mercado bursátil. La investigación analiza y compara múltiples modelos, desde modelos lineales tradicionales, árboles de decisión y algoritmos de gradient boosting, hasta arquitecturas de aprendizaje profundo más sofisticadas como redes neuronales recurrentes (RNNs) y redes neuronales convolucionales (CNNs). El estudio evalúa las capacidades predictivas de estos modelos tanto en acciones individuales como en índices bursátiles. Los resultados muestran que los modelos más simples como la regresión lineal y árboles de decisión funcionaron mejor que las arquitecturas complejas de aprendizaje profundo, y que, aunque predecir valores exactos es difícil, existe cierta capacidad para identificar la dirección de los movimientos del mercado.

ABSTRACT

This work studies the effectiveness of various machine learning and deep learning approaches in predicting stock market behavior. The research analyzes and compares multiple models, from traditional linear models, decision trees and gradient boosting algorithms, to more sophisticated deep learning architectures such as Recurrent Neural Networks (RNNs) and Convolutional Neural Networks (CNNs). The study evaluates these models' predictive capabilities on both individual stocks and stock indices. The results show that simpler models like linear regression and decision trees perform better than complex deep learning architectures, and that while predicting exact values is difficult, there is some capacity to identify the direction of market movements.

1. INTRODUCCIÓN

Esta sección presenta los aspectos fundamentales del trabajo sobre la predicción de mercados financieros. Primero se explica por qué este tema es importante en el sector económico actual y los problemas que existen con los métodos tradicionales. Luego se describen los desafíos técnicos específicos como la complejidad de los datos bursátiles y la hipótesis del mercado eficiente. Por último, se establecen los objetivos principales del trabajo: comparar diferentes modelos de aprendizaje automático para encontrar los más efectivos en la predicción de precios de acciones.

1.1. Motivación y contexto

El mercado de valores es un elemento clave para entender la situación económica de un país. Su comportamiento afecta a muchos sectores económicos diferentes, desde la banca hasta la agricultura. En los últimos años, la llegada de nuevas tecnologías como los sistemas automáticos de trading y las herramientas de análisis de datos ha cambiado la forma en que se estudian y operan los mercados financieros.

La motivación de este trabajo se origina en cuestiones relevantes en el sector financiero. Los métodos tradicionales de análisis del mercado de valores tienen algunas limitaciones. Por un lado, suelen analizar datos del pasado y no siempre son precisos en sus predicciones. Por otro lado, el precio de las acciones depende de muchos factores diferentes, como el crecimiento económico, los tipos de interés o el sentimiento de los inversores, y es muy difícil analizar todos estos factores de forma manual. Además, los inversores necesitan tomar decisiones rápidas basadas en mucha información, y los métodos tradicionales no son eficientes para procesar tanta información en poco tiempo.

El mercado de valores tiene oportunidades interesantes de rendimiento, pero también tiene riesgos altos debido a su volatilidad y a la incertidumbre. Para mejorar las posibilidades de obtener buenos resultados, los inversores necesitan entender bien el comportamiento de cada acción y los factores que influyen en su precio. Por esta razón, el sector busca nuevas técnicas basadas en machine learning y deep learning que puedan ayudar a tomar mejores decisiones de inversión.

Las técnicas de machine learning tienen unas ventajas importantes. Pueden procesar grandes cantidades de datos históricos, encontrar patrones complejos y hacer predicciones más precisas sobre cómo pueden cambiar los precios. También pueden

analizar muchos factores diferentes al mismo tiempo y adaptarse a distintas situaciones del mercado. Además, estas técnicas pueden ayudar a los inversores a tomar decisiones más rápidas y mejor informadas, lo que es especialmente importante en los mercados financieros actuales donde los precios cambian constantemente.

Este trabajo busca estudiar y comparar diferentes modelos de machine learning y deep learning para predecir el comportamiento del mercado de valores. El objetivo principal es descubrir qué métodos funcionan mejor y cómo se pueden usar en situaciones reales de mercado.

1.2. Planteamiento del problema

Esta sección presenta los desafíos fundamentales de la predicción bursátil mediante aprendizaje automático y define el alcance del trabajo como un análisis comparativo de diferentes modelos predictivos.

1.2.1. Descripción técnica del problema

La predicción bursátil presenta serios retos técnicos en el campo del aprendizaje automático. La naturaleza no lineal de los movimientos del mercado y la alta dimensionalidad de las características de entrada hacen especialmente difícil modelarlo matemáticamente. El problema puede tratarse tanto como una tarea de regresión (predicción de los valores exactos de los precios) como de clasificación (predicción de los movimientos direccionales), cada una con sus propias complicaciones.

La previsión de series temporales en los mercados financieros requiere manejar múltiples marcos temporales al mismo tiempo, desde movimientos de un día hasta tendencias a largo plazo. Esta dependencia temporal crea una complejidad adicional en el diseño y la aplicación de los modelos.

1.2.2. Desafíos específicos

Los métodos estadísticos tradicionales suelen fallar, ya que funcionan mejor para relaciones lineales y una distribución normal de los resultados, lo que rara vez es el caso en las condiciones reales del mercado [5]. Además, estos métodos tienen

dificultades en captar las complejas interacciones entre los distintos factores del mercado y a menudo funcionan peor durante los periodos de alta volatilidad [14].

La Hipótesis del Mercado Eficiente supone el principal reto, ya que propone que los precios actuales ya reflejan toda la información disponible [7]. Esto implica que cualquier patrón predecible se volverá rápidamente inútil y sólo podrá explotarse durante un breve periodo. Además, los datos del mercado contienen mucho ruido, lo que dificulta distinguir las señales reales de las fluctuaciones aleatorias.

Además de todo esto, existen desafíos relacionados con los datos, como la gestión de los valores faltantes, la selección de características relevantes entre cientos de indicadores potenciales y la gestión del desequilibrio natural de los datos financieros, en los que los movimientos significativos de los precios son eventos raros.

1.2.3. Alcance del problema

Este trabajo se centrará en comparar el rendimiento de modelos lineales, árboles de decisión, algoritmos de gradient boosting, RNNs y CNNs. El análisis evaluará su capacidad para predecir tanto los movimientos direccionales como los valores de los precios.

Los modelos se evaluarán con métricas estándar como accuracy, precision, recall, F1-score y MSE (error cuadrático medio) para predicciones numéricas. Además, el trabajo tendrá en cuenta aspectos prácticos como la eficiencia computacional y la aplicabilidad en el mundo real.

Este trabajo no intentará desarrollar nuevos enfoques algorítmicos ni crear un sistema de negociación completo, sino que se dedicará al análisis comparativo de los métodos existentes y su aplicabilidad a las tareas de predicción del mercado.

1.3. Objetivos del trabajo

Esta sección establece el objetivo principal de realizar un análisis comparativo de modelos de predicción bursátil y detalla los pasos metodológicos necesarios para completar el estudio.

1.3.1. Objetivo principal

El objetivo principal de este trabajo es realizar un análisis comparativo de los modelos de predicción del mercado de valores y encontrar los métodos más adecuados para predecir el comportamiento del mercado de valores, basado solamente en información estadística, es decir, los precios y algunos indicadores técnicos. Es importante señalar que la creación de un producto completamente desarrollado y optimizado para el comercio en un mercado bursátil real queda fuera del alcance de este estudio.

1.3.2. Objetivos Específicos

Esta subsección detalla los pasos concretos que se planea cumplir durante este trabajo para lograr el objetivo principal.

- 1) Realizar análisis de datos:
 - a. Encontrar y elegir los adecuados conjuntos de datos;
 - b. Realizar el preprocesamiento de datos y la ingeniería de features necesarios.
- 2) Analizar e implementar los modelos de predicción de mercados de valores:
 - a. Modelos tradicionales de aprendizaje automático (modelos lineales, árboles de decisión, gradient boosting);
 - b. Arquitecturas de aprendizaje profundo (RNNs, CNNs).
- 3) Evaluar modelos de predicción:
 - a. Realizar predicciones con diferentes targets;
 - b. Evaluar el funcionamiento de los modelos en diferentes métricas;
 - c. Visualizar los resultados;
 - d. Realizar un backtesting por cada modelo para evaluar su fiabilidad.
- 4) Realizar análisis comparativos:
 - a. Comparar los resultados de diferentes modelos;
 - b. Comparar y analizar los valores de las métricas de evaluación de los modelos;
 - c. Evaluar la aplicabilidad práctica.
- 5) Examinar las aplicaciones potenciales y las perspectivas de futuro:
 - a. Evaluar el potencial para desarrollar estrategias de trading beneficiosas basados en indicadores estadísticas;
 - b. Considerar las perspectivas de desarrollo futuro del estudio presente.

2. MARCO TEÓRICO Y ESTADO DEL ARTE

Esta sección presenta las bases teóricas y los avances recientes relacionados con el trabajo. Primero se explica cómo se aplica el aprendizaje automático en los mercados financieros, mostrando la evolución desde métodos tradicionales hacia técnicas más avanzadas. Después se describen en detalle los seis modelos que se analizarán: modelos lineales, árboles de decisión, XG-Boost y redes neuronales (RNN y CNN). Por último, se revisan los estudios previos más relevantes que han aplicado estas técnicas a la predicción bursátil, indicando sus principales resultados y problemas.

2.1. Aprendizaje Automático en Mercados Financieros

Predecir cómo se comporta la bolsa de valores ha sido siempre uno de los mayores retos en el mundo de las finanzas. Gracias a los avances en tecnología y sobre todo en inteligencia artificial, ahora tenemos nuevas y mejores maneras de intentar resolver este problema.

En el contexto de la predicción de precios de acciones, existen dos enfoques principales: el análisis fundamental y el análisis técnico. El análisis fundamental se centra en evaluar la salud financiera de una empresa, incluyendo sus estados financieros, proyecciones de ingresos, situación del mercado y otros factores económicos que podrían afectar su desempeño. Por otro lado, el análisis técnico se enfoca en estudiar los patrones históricos de los precios de las acciones, utilizando principalmente datos de series temporales para identificar tendencias y patrones que podrían repetirse en el futuro.

La aplicación de técnicas de aprendizaje automático ha revolucionado especialmente el análisis técnico. Los algoritmos modernos pueden procesar grandes cantidades de datos históricos para identificar patrones complejos que serían difíciles de detectar mediante métodos tradicionales. Desde los modelos lineales más simples hasta las arquitecturas más sofisticadas de aprendizaje profundo como las redes neuronales recurrentes y convolucionales, el campo ha evolucionado significativamente en las últimas décadas. Las técnicas avanzadas de gradient boosting y árboles de decisión han ampliado las posibilidades de análisis, lo que nos da muchas herramientas diferentes para intentar predecir el mercado.

Un aspecto importante en la evolución de estos métodos ha sido la incorporación del análisis de sentimientos. Los mercados financieros son sensibles a las noticias, las redes sociales y la opinión pública. Los modelos modernos pueden analizar datos textuales de noticias y redes sociales para evaluar el sentimiento del mercado y mejoran sus predicciones combinando estos datos con el análisis técnico tradicional.

La tendencia actual apunta hacia un enfoque híbrido que combina múltiples técnicas. Este método integrado utiliza tanto el análisis fundamental como el técnico, incorporando además el análisis de sentimientos y técnicas avanzadas de aprendizaje automático. Los modelos ensemble, que combinan las predicciones de varios algoritmos, han demostrado ser particularmente efectivos en este contexto.

Es importante mencionar que, aunque hemos avanzado mucho, la predicción del mercado de valores sigue siendo una tarea compleja debido a la naturaleza dinámica del mercado y la influencia de factores externos imprevisibles. Los modelos de inteligencia artificial deben actualizarse constantemente para mantener su eficacia y adaptarse a las cambiantes condiciones del mercado.

La investigación actual en este campo se centra en desarrollar modelos más robustos que puedan manejar la volatilidad del mercado y adaptar sus predicciones a diferentes condiciones económicas. También se está trabajando en mejorar la interpretabilidad de los modelos, un aspecto crucial para su aplicación práctica en la toma de decisiones financieras. Este trabajo se suma a dicha línea de investigación, explorando y comparando el rendimiento de diversos

s algorítmicos para identificar las técnicas más prometedoras en la predicción del comportamiento del mercado de valores.

2.2. Modelos de Aprendizaje Automático

Esta sección proporciona una descripción teórica de los diferentes algoritmos de aprendizaje automático potencialmente aplicables al alcance del estudio, desde métodos tradicionales hasta técnicas profundo y análisis de series temporales.

2.2.1. Modelos lineales

Los modelos lineales son una técnica básica pero muy útil para predecir el comportamiento de las acciones en el mercado. Su principal ventaja es que son fáciles de entender y usar, lo que los hace muy populares en el análisis financiero.

La regresión lineal, que es el tipo más común de modelo lineal, funciona buscando una relación directa entre diferentes datos. Por ejemplo, puede analizar cómo el precio de una acción se relaciona con factores como el volumen de compras, el precio de apertura del mercado o las tendencias anteriores. Esta relación se puede escribir con una fórmula simple:

$$y = \beta X + \alpha + \varepsilon$$

Donde y es el precio que queremos predecir, X son los datos que usamos para hacer la predicción, β indica cuánto influye cada dato, α es un valor fijo, y ε representa el margen de error.

Una de las mejores características de estos modelos es que nos permiten entender claramente cómo cada factor afecta al precio final. Por ejemplo, podemos ver si el volumen de operaciones tiene más o menos impacto que el precio de apertura en el precio final de una acción.

Los modelos lineales son una opción viable para analizar datos financieros, aunque presentan limitaciones importantes cuando se trata de capturar patrones no lineales y relaciones complejas. Además, se pueden adaptar a diferentes situaciones usando versiones más avanzadas como los Modelos Lineales Generalizados (GLM).

En la práctica, estos modelos se usan de dos formas principales:

- Para predecir precios exactos futuros
- Para predecir si el precio subirá o bajará

Para saber qué tan bien funciona el modelo, se utilizan medidas como el Error Cuadrático Medio (MSE) o el Error Absoluto Medio (MAE), que nos indican qué tan precisas son las predicciones.

Los modelos lineales también pueden mejorarse con técnicas especiales que evitan que el modelo se ajuste demasiado a los datos pasados, como la regularización L1

(Lasso), L2 (Ridge), la validación cruzada y la división temporal de datos en conjuntos de entrenamiento y prueba.

Aunque existen métodos más complejos, los modelos lineales siguen siendo muy importantes en el análisis financiero. Son una base excelente para empezar a analizar el mercado y sirven como punto de comparación para evaluar otros modelos más avanzados.

2.2.2. Árboles de decisión

Los árboles de decisión son algoritmos de aprendizaje automático que dividen los datos en subgrupos mediante una serie de decisiones secuenciales. Su estructura, esquematizada en la figura 1, consiste en un nodo raíz, nodos intermedios y nodos hoja, donde cada nodo representa una decisión basada en una característica específica de los datos.




Fig. 1: Arquitectura del modelo de árbol de decisión ([source](#))

En el contexto de la predicción bursátil, estos algoritmos evalúan diferentes variables del mercado en cada nodo. Por ejemplo, un nodo puede dividir los datos según el volumen de operaciones, mientras que otro puede usar la diferencia entre el precio actual y el promedio móvil. Este proceso continúa hasta llegar a los nodos hoja, que contienen las predicciones finales.

Los árboles de decisión pueden aplicarse tanto en problemas de regresión como de clasificación. En regresión, predicen valores numéricos específicos como precios futuros. En clasificación, determinan categorías como la dirección del movimiento del precio (subida o bajada).

Durante el entrenamiento, el algoritmo selecciona automáticamente las características y puntos de división óptimos para cada nodo. El objetivo de este proceso es maximizar la homogeneidad de los subgrupos resultantes, utilizando métricas como la ganancia de información o la reducción de la varianza.

Una ventaja significativa de los árboles de decisión es su interpretabilidad. Las reglas de decisión son explícitas y fáciles de seguir, lo que permite entender cómo el modelo llega a sus predicciones. Sin embargo, también tienen limitaciones, principalmente el riesgo de sobreajuste cuando el árbol crece demasiado. Para mitigar este problema, se implementan métodos de poda y se definen criterios de parada como la profundidad máxima del árbol o el número mínimo de muestras por nodo.

Los árboles de decisión sirven como base para algoritmos más avanzados como Random Forest y Gradient Boosting, que mejoran la capacidad predictiva combinando múltiples árboles.

2.2.3. Regresión XG-Boost

XGBoost (Extreme Gradient Boosting) es un algoritmo moderno de aprendizaje automático que ha ganado popularidad en la predicción de mercados financieros. A diferencia de un árbol de decisión simple, XGBoost utiliza múltiples árboles que trabajan juntos para hacer predicciones más precisas.

El funcionamiento básico de XGBoost se basa en un proceso de mejora continua. El algoritmo construye árboles de decisión uno tras otro, donde cada nuevo árbol aprende de los errores de los árboles anteriores. Cada árbol siguiente está específicamente diseñado para corregir las predicciones incorrectas de los árboles previos.

En el contexto de la predicción bursátil, XGBoost es útil porque maneja bien las características típicas de los datos financieros. Por ejemplo, puede trabajar eficientemente con múltiples variables como precios históricos, volúmenes de

operaciones e indicadores técnicos. Además, el algoritmo incluye métodos para evitar el sobreajuste.

Una ventaja de XGBoost es su capacidad para adaptar sus predicciones según diferentes objetivos. Por ejemplo, puede ajustarse para predecir precios exactos o para identificar tendencias de subida y bajada. Esto lo hace útil para diferentes estrategias de trading.

Aunque XGBoost es más complejo que un árbol de decisión simple, da mejores resultados en la mayoría de los casos. El algoritmo también puede mostrar qué variables son más importantes para hacer sus predicciones, lo que ayuda a entender mejor qué factores influyen más en el movimiento de los precios.

2.2.4. Redes neuronales recurrentes

Las Redes Neuronales Recurrentes (RNN) son modelos diseñados para procesar datos secuenciales, lo que las hace útiles para el análisis de series temporales financieras. A diferencia de otros modelos, las RNN pueden mantener información sobre datos anteriores, lo que les permite identificar patrones temporales en los precios de las acciones.

En el contexto de la predicción bursátil, la característica más relevante de las RNN es su capacidad para "recordar" información importante de periodos anteriores. Esto significa que el modelo puede considerar no solo el precio actual, sino también su evolución histórica para hacer predicciones más precisas.

Sin embargo, las RNN básicas tienen limitaciones al manejar dependencias temporales largas [20]. Para resolver este problema, se desarrollaron variantes más avanzadas como las redes LSTM (Long Short-Term Memory) y GRU (Gated Recurrent Unit). Estas variantes incluyen mecanismos especiales que les permiten saber qué información anterior es importante mantener y qué información se puede descartar. Por ejemplo, un diagrama más detallado de estructura de un bloque LSTM se muestra en la figura 2.




Fig. 2: Modelo LSTM ([source](#) [18])

Las LSTM, en particular, han demostrado ser efectivas en la predicción de mercados financieros [16] porque pueden captar patrones tanto a corto como a largo plazo. Por ejemplo, pueden identificar tendencias diarias y al mismo tiempo tener en cuenta los cambios de temporada o otros ciclos económicos.

En la práctica, estos modelos procesan los datos financieros como una secuencia temporal, donde cada punto representa un conjunto de características del mercado en un momento específico. El modelo aprende gradualmente qué patrones en estas secuencias son relevantes para predecir movimientos futuros del mercado.

Las RNN son útiles cuando se combinan con otros indicadores del mercado y cuando se dispone de series temporales largas para el entrenamiento. Sin embargo, hay que tener en cuenta que estos modelos requieren más recursos computacionales y datos de entrenamiento que métodos más simples como los árboles de decisión o la regresión lineal.

2.2.5. Redes neuronales convolucionales

Las Redes Neuronales Convolucionales (CNN) son modelos de aprendizaje profundo que fueron diseñados originalmente para el procesamiento de imágenes. Su característica principal es el uso de operaciones de convolución para detectar patrones espaciales en los datos de entrada.

La arquitectura básica de una CNN consiste en una serie de capas convolucionales que aplican filtros para detectar características, seguidas de capas de agrupación que

reducen la dimensionalidad de los datos. Las últimas capas suelen ser completamente conectadas y se encargan de combinar estas características para hacer la clasificación o regresión final. La figura 3 muestra esta arquitectura aplicada específicamente al procesamiento de series temporales.




Fig. 3: Arquitectura CNN para series temporales ([source](#) [9])

En el contexto del análisis financiero, las CNN procesan los datos temporales transformándolos en estructuras bidimensionales, donde una dimensión representa el tiempo y la otra diferentes variables o indicadores. Esta transformación hace posible aplicar las operaciones de convolución para detectar patrones en múltiples escalas temporales.

Para implementar CNN con datos bursátiles, es necesario organizar la información en ventanas temporales estructuradas. Cada ventana contiene un conjunto de variables financieras durante un periodo específico, creando así una representación que el modelo puede procesar mediante sus capas convolucionales.

Las CNN pueden ser eficientes para procesar datos en paralelo, pero no siempre son la mejor opción para datos financieros. Tienen limitaciones importantes: necesitan transformar los datos temporales a un formato específico y les cuesta captar relaciones a largo plazo sin modificar su estructura básica.

2.3. Trabajos relacionados

Muchos investigadores han estudiado cómo predecir los precios de las acciones usando datos históricos. Los primeros estudios usaban métodos simples como la regresión lineal. Por ejemplo, Yibin estudió varios métodos básicos como promedios móviles y regresión lineal para predecir precios de acciones [13].

Mark Dunne de Cork College hizo un estudio importante donde mostró que, aunque el precio teórico no tiene información útil, se pueden hacer buenas predicciones usando datos históricos y técnicas de aprendizaje automático [2].

En la Universidad de Teherán, Amin Hedayati y sus compañeros usaron redes neuronales para predecir los precios diarios del índice NASDAQ. Ellos tomaron datos de precios de 70 días para entrenar su modelo y 29 días para probarlo [12].

Elliot y Hsu compararon cuatro tipos de modelos: regresión lineal simple, modelo lineal generalizado, red neuronal recurrente (RNN) y un algoritmo de diseño en línea. Encontraron que el modelo RNN funcionaba mejor que los otros porque podía actualizar la información más rápido usando LSTM [3].

Khan y su equipo mejoraron estos resultados usando herramientas nuevas como Pyspark y MLlib. Con estas herramientas pudieron predecir precios con una precisión entre 80% y 98% [4].

Los métodos más nuevos combinan diferentes técnicas. Por ejemplo, Zhu y He compararon dos modelos populares: LSTM y random forest. En sus pruebas, encontraron que XG-Boost (un tipo de random forest mejorado) funcionaba mejor que LSTM [21].

Yang creó un modelo que usa dos tipos de redes neuronales juntas: LSTM y GRU. Este modelo obtuvo buenos resultados con un error RMSE muy bajo y una precisión del 60% [6]. Vuong y sus compañeros mejoraron aún más la precisión combinando XG-Boost con LSTM para manejar mejor grandes cantidades de datos [19].

Algunos investigadores han usado técnicas más avanzadas como aprendizaje por refuerzo y algoritmos genéticos. Estos métodos son buenos para analizar datos en diferentes periodos de tiempo y para combinar varios algoritmos de aprendizaje automático [11][15][17].

3. ASPECTOS METODOLÓGICOS

Esta sección describa los aspectos metodológicos del trabajo. Primero se establece la metodología general, dividida en tres fases: investigación, implementación y evaluación. Después se detalla el proceso de búsqueda y recogida de datos, incluyendo los criterios de selección de activos financieros, períodos temporales y targets de predicción. Luego se describe la investigación de features: tanto indicadores técnicos como económicos adicionales, y se presenta la estructura final de datos. Por último, se especifican las tecnologías empleadas en el desarrollo del trabajo.

3.1. Metodología general del trabajo

Esta subsección describe en detalle las tres fases, desde el estudio inicial de modelos y datos hasta la evaluación comparativa final de los resultados.

3.1.1. Fase de Investigación

Esta fase comprende dos tipos de investigación. Primero, la investigación teórica de modelos existentes adecuados para la tarea: modelos lineales, árboles de decisión, algoritmos de gradient boosting, redes neuronales recurrentes y convolucionales, tal como se presenta en la sección 2. Segundo, la investigación aplicada que incluye la selección y análisis de datos de entrenamiento, la evaluación inicial de features relevantes, y la toma de decisiones metodológicas específicas, aspectos que se detallan en las secciones 3.2 y 3.3.

3.1.2. Fase de Implementación

Esta fase se centra en el desarrollo técnico del sistema de evaluación mediante los siguientes pasos:

1. **Desarrollo del framework base:** implementación del preprocesamiento de datos, ingeniería de features y evaluadores comunes para todos los modelos.
2. **Preparación específica de datos por tipo de modelo:**
 - Modelos tradicionales (lineales y árboles de decisión) que trabajan con datos tabulares

- Redes neuronales (RNN y CNN) que requieren conversión de datos en secuencias de ventanas deslizantes

3. Implementación de arquitecturas específicas: desarrollo de aquellos modelos no predefinidos en las librerías correspondientes, como XGBoost.

3.1.3. Fase de Evaluación

Esta fase comprende la evaluación de todos los modelos implementados mediante los siguientes pasos:

1. Evaluación de modelos con métricas específicas por tipo de tarea:

- Modelos de regresión:
 - RMSE (error cuadrático medio): la magnitud promedio de los errores de predicción
 - MAE (error absoluto medio): el error promedio sin considerar la dirección
 - MAE%: el MAE como porcentaje del valor real
 - R^2 : proporción de la variabilidad explicada por el modelo
 - Directional accuracy: porcentaje de predicciones que aciertan la dirección del movimiento
- Modelos de clasificación: accuracy, precision, recall, F1-score, y curvas ROC
 - Accuracy: porcentaje total de predicciones correctas
 - Precision: proporción de predicciones positivas que fueron correctas
 - Recall: proporción de casos positivos reales que fueron identificados correctamente
 - F1-score: media armónica entre precision y recall
 - Curvas ROC: visualizan el rendimiento del clasificador en diferentes umbrales de decisión

2. **Visualización de resultados:** representación gráfica del rendimiento de cada modelo y comparación visual entre diferentes targets.
3. **Backtesting con métricas de trading:** evaluación específica basada en predicciones direccionales a 1 día, utilizando retorno acumulativo, ratio de Sharpe, tasa de éxito y precisión de operaciones.
4. **Análisis comparativo:** comparación de todos los resultados obtenidos con los valores de referencia del modelo Random Walk para establecer conclusiones sobre la efectividad de cada feature.

3.2. Búsqueda y recogida de datos

Para la obtención de datos se utilizó la biblioteca YFinance (Yahoo Finance), una librería de código abierto para Python que permite descargar durante la ejecución una amplia cantidad de datos gratuitos sobre el estado del mercado financiero. Esta herramienta proporciona información histórica diaria durante períodos temporales largos. Es una opción popular para el trabajo con datos de mercados financieros en Python. Los datos obtenidos presentan una estructura que resulta adecuada para los objetivos del trabajo.

3.2.1. Selección de tickers

Un ticker es el símbolo único que identifica un instrumento financiero específico en los mercados bursátiles. Para este trabajo se seleccionaron 7 tickers que incluyen tanto acciones individuales como índices bursátiles, con el objetivo de obtener una representación diversa del mercado por sectores.

Acciones individuales (diversidad sectorial y alta liquidez):

- Apple Inc. (AAPL): representa el sector tecnológico y electrónica de consumo
- Microsoft Corporation (MSFT): referente en tecnología y software empresarial
- Amazon.com Inc. (AMZN): refleja las tendencias de comercio electrónico y computación en la nube
- Tesla Inc. (TSLA): aporta volatilidad y representa el sector automotriz y energías renovables

Índices bursátiles (representación amplia del mercado):

- S&P 500 (^GSPC): proporciona una visión general del mercado estadounidense de gran capitalización

- Dow Jones Industrial Average (^DJI): incluye 30 grandes empresas industriales
- NASDAQ Composite (^IXIC): concentra empresas tecnológicas y de crecimiento

3.2.2. Selección del período temporal

Se seleccionó el período de 2014 a 2024 para el entrenamiento de los modelos con el objetivo de utilizar datos relativamente modernos y actuales. No se incluyeron datos hasta 2025 debido a la gran caída del mercado ocurrida en febrero de 2025, para evitar que este evento extraordinario influyera en la evaluación de los modelos. Tampoco se consideraron datos anteriores a 2014, ya que los patrones de mercado han evolucionado significativamente en la última década con la aparición del trading algorítmico, tal como se analiza en la sección 2 del punto de vista teórico.

La división temporal se estructuró de la siguiente manera:

- Train: 2014 - julio 2021
- Validación: julio 2021 - marzo 2023
- Test: abril 2023 - diciembre 2024

Esta división respeta tanto las proporciones estándar de entrenamiento/validación/prueba como la naturaleza continua de las series temporales, utilizando bloques temporales consecutivos en lugar de muestras aleatorias.

3.2.3. Selección de targets para predicción

El target define la variable objetivo que el modelo debe predecir y determina el tipo de modelo a implementar (regresión o clasificación). Para este trabajo se seleccionaron tres targets diferentes que permiten evaluar distintos aspectos predictivos del mercado.

Targets de regresión:

- Retorno a 1 día: predice la proporción de cambio del precio a corto plazo (ej.: de 50 a 52 = 0.04)
- Retorno a 5 días: predice la proporción de cambio del precio a medio plazo

Target de clasificación:

- Dirección a 1 día: predice si el precio subirá o bajará al día siguiente (problema binario)

Esta selección implica que cada modelo debe implementarse tres veces, una vez para cada target específico. Además, los diferentes tipos de targets requieren arquitecturas ligeramente distintas: en las redes neuronales, por ejemplo, la capa de salida varía conceptualmente según el tipo de predicción.

Los targets permiten comparar la capacidad predictiva tanto en términos de magnitud exacta del cambio (regresión) como de dirección del movimiento (clasificación), evaluando horizontes temporales de corto y medio plazo.

3.3. Investigación de features

Para determinar las variables de entrada más adecuadas para los modelos predictivos, se realizó una investigación detallada de las características disponibles en un notebook separado. Este análisis incluyó el estudio del poder predictivo de diferentes features, el cálculo de parámetros como la correlación de estas características con los cambios de precios, y la evaluación de su relevancia para las tareas de predicción.

3.3.1. YFinance features

Los datos originales obtenidos de YFinance proporcionan información serializada de precios con las siguientes características básicas:

- **Date**: día de negociación (utilizado como índice del DataFrame)
- **Open**: precio de la acción al abrir el mercado
- **High**: precio máximo alcanzado durante el día
- **Low**: precio mínimo alcanzado durante el día
- **Close**: precio de la acción al cierre del mercado
- **Adjusted Close**: precio de cierre ajustado por dividendos, divisiones de acciones y otras acciones corporativas
- **Volume**: número total de acciones negociadas durante el día

Tras analizar estas características, se decidió utilizar el precio de cierre ajustado (Adjusted Close) como variable principal para el entrenamiento de los modelos, ya que esta columna determina los dividendos que recibiría un agente que opere según las predicciones del modelo. Las demás columnas también se utilizan como features

adicionales, pero es a partir del precio de cierre ajustado que se calculan las variables derivadas.

3.3.2. Features derivados de precios

Features básicos:

- **Returns (retornos):** cambio porcentual diario del precio de cierre ajustado, calculado como $(\text{precio_actual} - \text{precio_anterior}) / \text{precio_anterior}$. Esta variable captura el rendimiento diario básico de cada acción.
- **Log returns (retornos logarítmicos):** logaritmo natural de la ratio entre precios consecutivos. Esta transformación ayuda a normalizar la distribución de los retornos y es útil para modelado estadístico.
- **Volume ratio (ratio de volumen):** volumen diario dividido por el promedio móvil de 20 días del volumen. Valores superiores a 1 indican actividad de trading por encima del promedio.
- **Features de calendario:** variables binarias que indican el primer día (lunes) y último día (viernes) de la semana bursátil, ya que estos días pueden presentar patrones de comportamiento diferentes.

Indicadores técnicos avanzados [1]:

La naturaleza serializada de los datos permite calcular indicadores técnicos más sofisticados:

- **RSI (Relative Strength Index):** oscilador de momentum que mide la velocidad y cambio de los movimientos de precios en una escala de 0 a 100. Valores por encima de 70 indican condiciones de sobrecompra, mientras que valores por debajo de 30 sugieren sobreventa.
- **MACD (Moving Average Convergence Divergence):** indicador de momentum que muestra la relación entre dos medias móviles de un precio. La línea MACD se calcula como la diferencia entre las medias móviles exponenciales de 12 y 26 días.
- **Bandas de Bollinger:** bandas de volatilidad colocadas por encima y por debajo de una media móvil. Se utiliza una SMA de 20 días con bandas a 2

desviaciones estándar, que se adaptan a los cambios de volatilidad del mercado.

- **SMA Crossover (50 días vs 200 días):** indicador de tendencia donde los cruces de estas medias móviles a largo plazo pueden señalar cambios importantes de tendencia. Un "golden cross" (la media de 50 días cruza por encima de la de 200) se considera alcista.
- **OBV (On-Balance Volume):** indicador de momentum basado en volumen que suma el volumen en días alcistas y lo resta en días bajistas, creando un total acumulado que puede confirmar las tendencias de precios.




Fig. 4: Correlaciones de features con 5-d retornos

Se analizaron las correlaciones de estos indicadores con uno de los targets (retorno a 5 días) en diferentes regímenes de volatilidad, generando visualizaciones que permitieron evaluar su potencial predictivo (figura 4). Los mapas de calor muestran que las correlaciones son generalmente débiles en todos los regímenes, con valores concentrados cerca de cero. Durante períodos de alta volatilidad, las correlaciones tienden a volverse más negativas, especialmente para las acciones individuales como AMZN y TSLA.

3.3.3. Indicadores económicos adicionales

Aunque según la teoría del mercado eficiente toda la información necesaria para predecir los precios de los valores está contenida en los propios precios, trabajos

previos demuestran que estos datos no son realmente suficientes y la hipótesis no es correcta [8][10]. Por esta razón se decidió investigar el uso no solo de los precios y sus features derivados, sino también de otros indicadores macroeconómicos adicionales.

Los datos macroeconómicos se obtuvieron de FRED (Federal Reserve Economic Data), una base de datos económica utilizada para investigación financiera [b]. Los conjuntos de datos específicos utilizados están disponibles en las series VIXCLS, GDP y T10YIE de FRED:

- **GDP (Producto Interno Bruto):** representa el crecimiento económico general y permite distinguir entre períodos de expansión y contracción económica. Los datos se proporcionan trimestralmente y durante el preprocesamiento se copió el valor a cada día del trimestre correspondiente.
- **T10YIE (Inflación a 10 años):** refleja las expectativas de inflación del mercado y el entorno monetario. Este indicador influye en las decisiones de inversión y la valoración de activos financieros.
- **VIXCLS (Volatility Index):** mide la volatilidad esperada del mercado y se conoce como el "índice de miedo". Este indicador permite identificar períodos de alta incertidumbre del mercado.

A partir de estos indicadores se crearon dos tipos de regímenes de mercado para usar como features categóricas:

- **Regímenes de volatilidad:** basados en el VIX, se clasificaron los períodos en tres categorías: volatilidad baja ($VIX < 15$), media ($15 \leq VIX < 25$) y alta ($VIX \geq 25$). Esta división permite a los modelos ajustar sus predicciones según las condiciones de incertidumbre del mercado.
- **Regímenes económicos:** basados en el cambio del GDP trimestral, se clasificaron los períodos en expansión económica (crecimiento del GDP > 0) y contracción económica (crecimiento del GDP < 0). Esta clasificación captura los ciclos económicos básicos.

El análisis inicial reveló que estos indicadores presentan correlaciones débiles con los precios de forma individual, pero pueden proporcionar información contextual valiosa cuando se combinan.

3.3.4. Estructura final de datos

La combinación de todas las características analizadas se integró en una tabla única (las columnas y sus descripciones se presentan en la figura 5) que posteriormente se dividió en siete tablas separadas por ticker para garantizar la consistencia temporal. Cada tabla contiene datos de precios serializados temporalmente para un único ticker, donde la fecha se incrementa por días hábiles en cada entrada consecutiva.

Nombre de la columna	Descripción	Tipo
Date	Día de negociación	Index
Open	Precio al abrir el mercado	Numerical
High	Precio máximo del día	Numerical
Low	Precio mínimo del día	Numerical
Close	Precio al cierre del mercado	Numerical
Adj. Close	Precio de cierre ajustado	Numerical
Volume	Número de acciones negociadas	Numerical
RSI	Oscilador de momentum (0-100)	Numerical
MACD	Indicador de momentum basado en medias móviles	Numerical
Bollinger Bands	Bandas de volatilidad adaptativas	Numerical
SMA	Indicador de tendencia a largo plazo	Numerical
OBV	Indicador de momentum basado en volumen	Numerical
GDP	Indicador de crecimiento económico trimestral	Numerical
T10YIE	Tasa de inflación	Numerical
VIXCLS	Índice de volatilidad del mercado	Numerical
economic_regime	Régimen económico (expansión/contracción)	Categorical
volatility_regime	Régimen de volatilidad (bajo/medio/alto)	Categorical
Sector	Sector económico (tecnología, e-commerce, automotriz, índice)	Categorical
return_1d	Retorno porcentual a 1 día	Target
return_5d	Retorno porcentual a 5 días	Target
direction_1d	Dirección del movimiento (subida/bajada)	Target

Fig. 5: Estructura final de datos

Esta estructuración permite que cada modelo trabaje con series temporales consistentes y completas para cada activo financiero, facilitando tanto el entrenamiento como la evaluación de los algoritmos predictivos. La estructura final incluye todas las features derivados de precios y de indicadores económicos adicionales.

Es importante entender que algunas de estas features pueden no tener valor predictivo significativo, pero dado que no se conoce a priori cuáles serán relevantes, se incluyen todas en el análisis inicial para permitir que los modelos determinen su importancia durante el proceso de entrenamiento.

3.4. Tecnologías empleadas

Python se seleccionó como lenguaje de programación principal debido a su amplio uso en machine learning, su naturaleza de alto nivel que facilita el desarrollo, su eficiencia computacional y la abundante disponibilidad de librerías especializadas para tareas específicas.

Herramientas de desarrollo:

- **Jupyter Notebook:** entorno interactivo para desarrollo y experimentación con código
- **Librerías Python utilizadas:**
 - **Manipulación de datos:**
 - **NumPy:** operaciones numéricas y álgebra lineal
 - **Pandas:** manipulación y análisis de datos estructurados
 - **Pandas_TA:** extensión especializada para análisis técnico de datos financieros
 - **Matplotlib:** visualización de datos y generación de gráficos
 - **Librerías de Machine Learning:**
 - **TensorFlow + Keras:** implementación de redes neuronales y modelos de deep learning
 - **Scikit-learn:** algoritmos de machine learning tradicional y herramientas de evaluación
 - **XGBoost:** implementación específica para modelos de gradient boosting
 - **Fuente de datos:**
 - **YFinance:** obtención de datos financieros históricos en tiempo real

4. DESARROLLO DEL TRABAJO

Esta sección presenta la implementación práctica del sistema de predicción bursátil y el análisis de los resultados obtenidos. Primero se describe el desarrollo del proyecto modular en Python, incluyendo la arquitectura de datos, la implementación de los diferentes modelos de aprendizaje automático y el sistema de evaluación. Después se analiza el rendimiento de los modelos implementados, tanto en tareas de regresión como de clasificación, mediante métricas estándar y técnicas de backtesting. Para consultar los detalles técnicos del proyecto se puede acceder al repositorio de GitHub [a]. Su página principal se muestra en la figura 6.




Fig. 6: Página principal del repositorio GitHub del proyecto

4.1. Implementación del Sistema

Para desarrollar este proyecto se creó una aplicación modular en Python que permite entrenar, evaluar y comparar diferentes modelos de aprendizaje automático para la predicción bursátil. El sistema está organizado en módulos especializados que gestionan distintos aspectos del proceso: la descarga y procesamiento de datos, la

implementación de los modelos, la evaluación de resultados y la visualización de métricas.

La aplicación incluye una interfaz de línea de comandos (CLI) que facilita la gestión de todos los componentes del sistema de forma integrada. Esta interfaz permite mostrar el estado de los modelos, entrenarlos individualmente o en conjunto, evaluar su rendimiento y generar visualizaciones de los resultados. La figura 7 muestra el aspecto de esta interfaz al iniciar el proyecto, donde se pueden observar los comandos disponibles y el estado inicial del sistema.

```
✓ gru_return_1d loaded
✓ gru_direction_1d loaded
✓ gru_return_5d loaded
✓ cnn_return_1d loaded
✓ cnn_direction_1d loaded
✓ cnn_return_5d loaded

System ready.
-----

Available commands:
models      - Show model status
train       - Train a model on a specific target (e.g., 'train xgboost return_1d' or 'train linear')
evaluate    - Evaluate models (e.g., 'evaluate' or 'evaluate lstm xgboost')
backtest    - Backtest a model (e.g., 'backtest lstm')
plot        - Generate plots (e.g., 'plot scatter' for all models or 'plot scatter xgboost')
help        - Show this help message
exit (q)    - Exit program
-----

Available models: linear, arima, tree, xgboost, lstm, gru, cnn
Available targets: return_1d, direction_1d, return_5d
Available plots: scatter, line, bar, class_heatmap, return_heatmap, backtest_heatmap, regime, confusion, roc
-----

> █
```

Fig. 7: Interfaz de línea de comandos (CLI) del sistema implementado

La arquitectura modular del proyecto garantiza que cada componente tenga una responsabilidad específica y bien definida, lo que facilita tanto el desarrollo como el mantenimiento del código.

4.1.1. Procesamiento de datos por tipo de modelo

Diferentes modelos de aprendizaje automático requieren formatos de datos distintos, por lo que se implementó un sistema de procesamiento que adapta automáticamente los datos según el tipo de modelo que se vaya a entrenar.

Modelos tabulares: Los modelos lineales, árboles de decisión y XGBoost trabajan con datos en formato tabular tradicional. En este caso, se dividen las características en numéricas y categóricas. Las características numéricas se mantienen tal como están,

mientras que las categóricas se codifican mediante one-hot encoding. Dado que estos modelos procesan un registro a la vez, es posible concatenar datos de diferentes acciones en un único conjunto de entrenamiento.

Modelos secuenciales: Las redes neuronales recurrentes (LSTM y GRU) y convolucionales requieren secuencias de datos temporales. Para estos modelos, las características categóricas se codifican mediante label encoding y se procesan a través de capas de embedding. Para cada punto en el conjunto de datos, se crea una ventana deslizante que contiene una secuencia de registros anteriores con una longitud predefinida de 20 a 40 días, dependiendo del modelo específico.

Durante esta etapa también se realiza la división de los datos en conjuntos de entrenamiento, validación y prueba. Para mantener la consistencia temporal, crucial en datos financieros, se utilizan divisiones basadas en fechas específicas en lugar de muestreo aleatorio. Para los modelos secuenciales, se añade un buffer de fechas anteriores a los conjuntos de validación y prueba, permitiendo que el modelo genere ventanas deslizantes completas para todos los puntos de evaluación.

4.1.2. Arquitectura base para los modelos

Se desarrolló una clase base abstracta (ABC) que define la interfaz común para todos los modelos implementados. Esta arquitectura garantiza la consistencia en el tratamiento de datos y la evaluación de resultados, independientemente del tipo específico de modelo utilizado.

Cada modelo que hereda de esta clase base implementa tres métodos principales: preparación de datos, construcción del modelo y entrenamiento. El método de preparación de datos ejecuta automáticamente el procesamiento descrito en la sección anterior según el tipo de modelo. La construcción determina la arquitectura específica del modelo, mientras que el entrenamiento ajusta los parámetros utilizando los datos procesados.

Un aspecto importante de esta arquitectura es que cada modelo se entrena por separado para cada uno de los tres objetivos de predicción definidos: retorno a 1 día, dirección a 1 día y retorno a 5 días. Esto significa que se crean modelos

especializados para cada tarea, optimizando su rendimiento para el objetivo específico.

La clase base también gestiona automáticamente el almacenamiento y la carga de modelos entrenados, incluyendo todos los datos necesarios para realizar predicciones futuras. Esto incluye no solo los pesos del modelo, sino también los escaladores de características, los datos de prueba y los metadatos necesarios para la evaluación.

4.1.3. Implementación de los modelos específicos

Se implementaron cuatro tipos diferentes de modelos. Aquí se presentan en orden de complejidad:

Modelos lineales: Se implementó regresión lineal para tareas de regresión y regresión logística para clasificación. Estos modelos incluyen ajuste automático de hiperparámetros mediante validación cruzada, probando diferentes valores de regularización para optimizar el rendimiento en el conjunto de validación.

Modelos basados en árboles: Se desarrollaron dos variantes: árboles de decisión individuales y XGBoost. Los árboles de decisión sirven como línea base, mientras que XGBoost implementa técnicas avanzadas de gradient boosting con parada temprana para evitar el sobreajuste.

Redes neuronales recurrentes: Se implementaron arquitecturas LSTM y GRU con capas de embedding para características categóricas y escalado automático para características numéricas. Estos modelos incluyen técnicas de regularización como dropout y reducción adaptativa de la tasa de aprendizaje.

Redes neuronales convolucionales: Se adaptó la arquitectura CNN para el procesamiento de series temporales financieras, utilizando convoluciones unidimensionales sobre ventanas temporales. El modelo combina las características numéricas escaladas con embeddings de características categóricas antes de aplicar las capas convolucionales.

Todos los modelos implementan métodos consistentes para generar predicciones, incluyendo la capacidad de devolver probabilidades para modelos de clasificación, lo que permite análisis posteriores de confianza y backtesting.

4.1.4. Sistema de evaluación y métricas

Se desarrolló un sistema de evaluación que calcula métricas estándar para cada tipo de modelo y tarea de predicción. Para modelos de regresión, se calculan métricas como RMSE, MAE, MAE% R^2 y precisión direccional. Para modelos de clasificación, se evalúan la precisión, recall, F1-score y el área bajo la curva ROC.

El sistema de evaluación también incluye análisis específicos para trading, como backtesting basado en confianza para modelos de clasificación. Este análisis simula estrategias de trading que solo realizan operaciones cuando la confianza del modelo supera un umbral determinado, calculando métricas como retorno acumulativo, tasa de acierto y ratio de Sharpe.

El sistema genera automáticamente visualizaciones de todos los resultados, incluyendo gráficos de dispersión, matrices de confusión, curvas ROC y mapas de calor que comparan el rendimiento de diferentes modelos. Estas visualizaciones se guardan automáticamente y pueden generarse bajo demanda a través de la interfaz de línea de comandos.

4.2. Análisis de Resultados

En esta sección se analiza el rendimiento de todos los modelos implementados utilizando los datos de prueba. Se evalúan dos tipos de tareas de predicción: la regresión, donde los modelos intentan predecir los valores exactos de los retornos futuros, y la clasificación, donde predicen la dirección del movimiento de precios. En ambos casos se compara el rendimiento de los modelos contra líneas base aleatorias para determinar su utilidad práctica en estrategias de trading.

4.2.1. Modelos de regresión

Los modelos de regresión se diseñaron para predecir los valores exactos de los retornos futuros, implementando dos tipos: modelos de 1 día para representar cambios de mercado a corto plazo y modelos de 5 días para representar cambios de mercado a medio plazo. Para evaluar su rendimiento se analizan tres aspectos: la precisión en la predicción de valores mediante el error cuadrático medio (RMSE), la correlación entre predicciones y valores reales a través del coeficiente R^2 , y la capacidad de predecir correctamente la dirección del movimiento de precios. Estas métricas se

comparan sistemáticamente con líneas base aleatorias para determinar si alguno de los modelos logra superar el rendimiento de predicciones aleatorias, lo cual ya constituiría un logro significativo en el contexto de predicción bursátil.

4.2.1.1. Rendimiento en Error Cuadrático Medio

Las figuras 7 y 8 muestran el rendimiento RMSE de todos los modelos comparado con una línea base de caminata aleatoria (Random-Walk). Para retornos a 1 día (figura 8), todos los modelos presentan barras rojas, indicando que ninguno consigue superar la precisión del modelo de caminata aleatoria. Los valores RMSE oscilan entre 0.0178 y 0.0284, con el modelo LSTM mostrando el mejor rendimiento y GRU el peor.




Fig. 8: Comparación RMSE para retornos a 1 día vs línea base Random Walk




Fig. 9: Comparación RMSE para retornos a 5 días vs línea base Random Walk

Para retornos a 5 días (figura 9), el panorama cambia. El modelo lineal aparece en verde, siendo el único que supera la línea base con un RMSE de 0.0407 frente al 0.0414 de la caminata aleatoria. Los demás modelos mantienen un rendimiento inferior, sugiriendo que la complejidad adicional de las redes neuronales no se traduce en mejores predicciones para este horizonte temporal.

4.2.1.2. Correlación entre Predicciones y Valores Reales

Los gráficos de dispersión muestran la relación entre los valores predichos y los valores reales de los retornos, donde una correlación perfecta aparecería como una línea diagonal. Los resultados confirman la ausencia de capacidad predictiva en todos los modelos evaluados.




Fig. 10: Gráficos de dispersión predicciones vs valores reales - retornos 1 día

La figura 10 presenta los resultados para predicciones a 1 día. Todos los modelos muestran valores R^2 negativos, lo que indica un rendimiento inferior al de una predicción constante. Los puntos se distribuyen sin patrón aparente alrededor del eje horizontal, concentrándose cerca de cero en el eje de predicciones. Esta distribución indica que los modelos no capturan la variabilidad real de los retornos del mercado. El modelo GRU presenta el peor valor R^2 (-1.559), mientras que LSTM obtiene el mejor resultado (-0.009), aunque ambos permanecen en territorio negativo.




Fig. 11: Gráficos de dispersión predicciones vs valores reales - retornos 5 días

La figura 11 muestra resultados similares para el horizonte de 5 días. El modelo LINEAR es el único que obtiene un R^2 positivo (0.004), aunque este valor es prácticamente insignificante. Los demás modelos mantienen valores R^2 negativos, con XGBOOST mostrando el peor rendimiento (-0.305). La dispersión de puntos sigue el mismo patrón que en el horizonte de 1 día, sin correlación visible entre predicciones y valores reales.

4.2.1.3. Precisión Direccional

La precisión direccional mide la capacidad de los modelos para predecir correctamente la dirección del movimiento de precios, independientemente de la magnitud exacta del cambio. Esta métrica resulta más relevante para aplicaciones de trading que la predicción de valores exactos.




Fig. 12: Precisión direccional por modelo comparada con línea base aleatoria

La figura 12 compara el rendimiento direccional de todos los modelos para ambos horizontes temporales. La mayoría de los modelos obtienen precisiones direccionales entre 50% y 60%, superando ligeramente el 50% que representa la precisión aleatoria. Los modelos TREE y LINEAR alcanzan los mejores resultados en ambos horizontes, con precisiones cercanas al 60% para retornos a 5 días. El modelo CNN es el único que no supera la línea base aleatoria en el horizonte de 1 día, con una precisión del 48%. Los modelos de redes neuronales (LSTM, GRU, CNN) no muestran ventajas

consistentes sobre los métodos más simples en esta métrica, y en algunos casos obtienen resultados inferiores.

4.2.1.4. Análisis Comparativo con Líneas Base

Los mapas de calor proporcionan una evaluación sistemática del rendimiento de cada modelo comparado con líneas base aleatorias. El código de colores permite identificar rápidamente qué métricas superan (verde) o no alcanzan (rojo) el rendimiento de referencia.




Fig. 13: Mapa de calor: rendimiento de modelos de regresión a 1 día vs líneas base

La figura 13 muestra que los modelos de 1 día fallan en las métricas más importantes para la predicción de valores exactos. Todos los modelos aparecen en rojo para RMSE, MAE% y R², indicando que no pueden superar las líneas base de caminata aleatoria. Solo consiguen superar la línea base en MAE y precisión direccional. El modelo CNN presenta el peor rendimiento general, siendo el único que no supera ni siquiera la precisión direccional aleatoria del 50%.




Fig. 14: Mapa de calor: rendimiento de modelos de regresión a 5 días vs líneas base

La figura 14 muestra un panorama un poco diferente para el horizonte de 5 días. El modelo LINEAR es el único que presenta una fila completamente verde, superando todas las líneas base de referencia. Los demás modelos mantienen dificultades en RMSE y R², pero mejoran su rendimiento en precisión direccional comparado con el horizonte de 1 día. Todos los modelos superan la línea base en MAE y precisión direccional, con valores que oscilan entre 53.9% y 59.9% para esta última métrica.

4.2.1.5. Conclusiones del Análisis de Regresión

Los resultados del análisis de regresión confirman la dificultad inherente de predecir valores exactos de retornos en mercados financieros. Los modelos evaluados no consiguen superar consistentemente las líneas base aleatorias en las métricas de precisión numérica, con valores R² negativos que indican un ajuste peor que una predicción constante.

El modelo LINEAR presenta el mejor rendimiento general, siendo el único que supera todas las líneas base en el horizonte de 5 días. Los modelos de aprendizaje profundo no muestran ventajas sobre métodos más simples, y en algunos casos obtienen resultados inferiores. El modelo CNN presenta el peor rendimiento en ambos horizontes temporales.

La métrica de precisión direccional ofrece resultados más alentadores, con la mayoría de los modelos superando el 50% aleatorio. Esta observación propone que, aunque los modelos fallan en predecir magnitudes exactas, mantienen cierta capacidad para identificar la dirección de los movimientos del mercado. Esta característica podría ser más relevante en aplicaciones prácticas de trading, donde las decisiones binarias de compra o venta son más importantes que los valores exactos de los retornos.

4.2.2. Modelos de clasificación

Los modelos de clasificación se diseñaron para predecir la dirección del movimiento de precios (subida o bajada) al día siguiente. Estos modelos resultan más adecuados para aplicaciones de trading que los modelos de regresión, ya que las decisiones de inversión son fundamentalmente binarias (comprar o vender) y dependen más de la dirección del movimiento que del valor exacto del precio futuro. Aunque están entrenados específicamente para maximizar la precisión en la predicción direccional, su evaluación incluye tanto métricas estándar de clasificación (accuracy, precision, recall, F1-score y curvas ROC) como análisis de rendimiento en estrategias de trading simuladas que calculan métricas financieras por ticker. Este análisis permite determinar si la capacidad predictiva direccional se traduce en ventajas prácticas para la toma de decisiones de inversión.

4.2.2.1. Métricas de Clasificación Estándar

El análisis de las métricas de clasificación confirma que ningún modelo logra superar de forma significativa el rendimiento aleatorio del 50%. Los resultados obtenidos reflejan la dificultad inherente de la predicción direccional en mercados financieros.




Fig. 15: Matrices de confusión para modelos de clasificación direccional

Las matrices de confusión de la figura 15 muestran dos patrones principales. Los modelos LINEAR, LSTM y GRU muestran una tendencia marcada hacia predicciones de subida, prediciendo "subida" en la mayoría de casos independientemente de la dirección real del mercado. Este comportamiento explica por qué estos modelos obtienen valores de recall altos, pero precisión baja. El modelo CNN presenta el comportamiento opuesto, con accuracy inferior al 50%, lo que muestra un rendimiento peor que las predicciones aleatorias.




Fig. 16: Curvas ROC comparativas para predicción direccional

Las curvas ROC de la figura 16 muestran que todos los modelos están muy cerca de la línea diagonal que representa el rendimiento aleatorio. Los valores AUC van entre 0.492 y 0.514, confirmando la ausencia de capacidad discriminativa real. Esta proximidad a 0.500 muestra que los modelos no pueden distinguir de forma consistente entre movimientos de subida y de bajada.




Fig. 17: Mapa de calor: métricas de clasificación por modelo

El mapa de calor de la figura 17 evidencia la dificultad inherente de la predicción bursátil: los modelos obtienen recall alto a costa de precision muy baja. Los modelos LINEAR y GRU obtienen recall superior a 0.9, pero esto se debe a su estrategia de predecir casi siempre "subida". En consecuencia, sus valores de precision se mantienen próximos a 0.55, solo por encima de lo aleatorio. El modelo CNN presenta el patrón inverso con recall muy bajo, lo que explica su bajo rendimiento general. Ningún modelo logra un equilibrio adecuado entre precision y recall, como reflejan los valores mediocres de F1-score.

4.2.2.2. Rendimiento en Trading

Para evaluar si la capacidad predictiva direccional se traduce en ventajas prácticas para estrategias de inversión, se realizó un análisis de backtesting basado en confianza. Este método simula operaciones de trading donde solo se ejecutan transacciones cuando la confianza del modelo supera un umbral del 20%. Las estrategias simuladas van en largo cuando el modelo predice subida y en corto cuando predice bajada, comparando su rendimiento contra líneas base de buy-and-hold.




Fig. 18: Mapas de calor: rendimiento de trading por ticker (LINEAR)




Fig. 19: Mapas de calor: rendimiento de trading por ticker (TREE)




Fig. 20: Mapas de calor: rendimiento de trading por ticker (XGBOOST)




Fig. 21: Mapas de calor: rendimiento de trading por ticker (LSTM)




Fig. 22: Mapas de calor: rendimiento de trading por ticker (GRU)

Los mapas de calor de las figuras 18 a 22 muestran el rendimiento de trading de cada modelo evaluado en cuatro métricas clave: retorno acumulado, ratio de Sharpe, tasa de éxito y precisión direccional. El color verde indica que el modelo supera la línea base correspondiente, mientras que el rojo señala un rendimiento inferior.

Los resultados confirman las limitaciones observadas en las métricas de clasificación estándar. Ningún modelo consigue superar consistentemente las líneas base de buy-and-hold en términos de retorno acumulado. Todos los modelos muestran celdas rojas en esta métrica crítica, indicando que las estrategias basadas en predicciones direccionales no generan retornos superiores a simplemente mantener las posiciones.

El modelo LINEAR presenta el rendimiento más equilibrado, con algunos valores positivos en ratio de Sharpe para ciertos activos como MSFT y AMZN. Sin embargo, sus retornos acumulados permanecen por debajo de las líneas base

en todos los casos. El modelo TREE muestra resultados similares, pero con mayor variabilidad entre activos.

El modelo XGBOOST muestra el peor rendimiento general, con prácticamente todas las métricas en rojo. Este resultado contradice las expectativas basadas en la reputación de XGBoost en otros dominios, proponiendo que la complejidad del algoritmo no se traduce en mejores predicciones para datos financieros.

Los modelos de redes neuronales (LSTM y GRU) muestran patrones interesantes en ratios de Sharpe, ocasionalmente superando las líneas base. Sin embargo, esto no se traduce en retornos acumulativos superiores, lo que sugiere que estos modelos pueden generar retornos más consistentes, pero de menor magnitud.

Es importante señalar que el modelo CNN no aparece en este análisis de trading porque ninguna de sus predicciones alcanzó el umbral mínimo de confianza del 20% requerido para ejecutar operaciones. Esta ausencia total de predicciones con confianza suficiente confirma el bajo rendimiento del modelo CNN observado en las métricas de clasificación estándar.




Fig. 23: Backtesting detallado del modelo GRU en TSLA (mejor caso)

Para analizar el comportamiento temporal de las estrategias, se examinan dos casos extremos. La figura 23 muestra el mejor rendimiento observado: el modelo

GRU aplicado a TSLA. Con solo 17 operaciones durante el período de prueba, la estrategia alcanza un retorno acumulativo del 28% y una tasa de éxito del 70.6%. El gráfico de retornos individuales muestra que la mayoría de las operaciones generan ganancias modestas entre 2% y 5%, con pocas pérdidas significativas. Sin embargo, el análisis de precisión direccional muestra alta volatilidad en la capacidad predictiva, con periodos donde la precisión cae por debajo del nivel aleatorio.




Fig. 24: Backtesting detallado del modelo XGBoost en ^GSPC (peor caso)

El contraste se observa en la figura 24, que presenta el peor caso: XGBoost aplicado al índice S&P 500. Con 364 operaciones, este modelo genera un retorno acumulativo negativo del 4% y una tasa de éxito apenas superior al 50%. El gráfico muestra una alta frecuencia de operaciones con retornos individuales muy pequeños, típicamente entre -1% y 1%. La precisión direccional fluctúa drásticamente, con periodos prolongados por debajo del nivel aleatorio, lo que explica el rendimiento negativo acumulativo.

La comparación entre estos casos extremos revela aspectos importantes sobre el comportamiento de los modelos. Las estrategias con pocas operaciones de alta confianza (como GRU en TSLA) pueden generar resultados positivos, pero dependen de la selección adecuada del activo y del período temporal. Las estrategias con alta frecuencia de operaciones (como XGBoost en índices) tienden a acumular costos de transacción y errores de predicción, resultando en rendimientos negativos.

4.2.2.3. Conclusiones del Análisis de Clasificación

El análisis de los modelos de clasificación muestra que ninguno consigue superar de forma consistente el rendimiento aleatorio, tanto en métricas tradicionales como en aplicaciones prácticas de trading. Los resultados confirman la dificultad inherente de la predicción direccional en mercados financieros.

Los modelos muestran dos problemas fundamentales. Primero, la tendencia a generar predicciones con inclinación hacia una dirección (principalmente "subida"), lo que resulta en alta sensibilidad pero baja precisión. Segundo, la incapacidad de mantener un rendimiento predictivo estable a lo largo del tiempo, como evidencian las fluctuaciones extremas en las métricas de precisión direccional.

El análisis de backtesting demuestra que incluso cuando los modelos consiguen precisión direccional superior al 50%, esto no se traduce en ventajas económicas reales. Las estrategias basadas en estas predicciones no superan las líneas base de buy-and-hold, y en muchos casos generan retornos negativos debido a la acumulación de errores de predicción y costos implícitos de transacción.

La comparación entre casos extremos (GRU en TSLA versus XGBoost en S&P 500) muestra que el rendimiento de los modelos depende fuertemente de la selección del activo y del período temporal específico, lo que limita su aplicabilidad general. Los modelos que generan pocas operaciones de alta confianza pueden mostrar resultados temporalmente favorables, pero esta selectividad reduce significativamente las oportunidades de trading.

Estos resultados apoyan la hipótesis del mercado eficiente y confirman que las técnicas de aprendizaje automático evaluadas no consiguen extraer patrones predictivos consistentes y económicamente viables de los datos históricos de precios y indicadores técnicos utilizados.

5. CONCLUSIONES

Esta sección presenta las principales conclusiones del trabajo realizado. Primero se revisa el desarrollo del trabajo completado, después se analizan los resultados más importantes obtenidos durante la investigación, y luego se identifican las direcciones para futuros desarrollos en este campo.

5.1. Desarrollo del Trabajo Realizado

Este trabajo completó todas las tareas necesarias para analizar y comparar modelos de aprendizaje automático en predicción bursátil.

- **Análisis de datos completado:** Se seleccionaron 7 activos financieros de Yahoo Finance que incluyen 4 acciones individuales y 3 índices bursátiles. Se creó un sistema completo de preprocesamiento que incluye 19 características finales, combinando indicadores técnicos como RSI, MACD, Bandas de Bollinger, SMA y OBV con datos económicos como GDP, VIX y T10YIE. Se crearon regímenes de mercado basados en volatilidad y ciclos económicos.
- **Modelos de predicción desarrollados:** Se implementaron modelos tradicionales que incluyen regresión lineal, árboles de decisión y XGBoost con ajuste de parámetros. También se desarrollaron arquitecturas de aprendizaje profundo como redes LSTM, GRU y CNN modificadas para series temporales financieras. Todos los modelos se crearon para tres tipos de predicción diferentes: retorno a 1 día, retorno a 5 días y dirección a 1 día.
- **Evaluación completa realizada:** Se midieron métricas apropiadas para cada tipo de predicción, incluyendo RMSE, MAE, R^2 y precisión direccional para regresión, y accuracy, precision, recall y F1-score para clasificación. Se crearon visualizaciones completas con gráficos de dispersión, matrices de confusión, curvas ROC y mapas de calor. Se realizó backtesting basado en confianza para evaluar el rendimiento en trading simulado.
- **Análisis de comparación completado:** Se comparó el rendimiento de todos los modelos contra líneas base aleatorias tipo Random Walk. Se encontró un orden de rendimiento donde los modelos más simples como LINEAR y TREE funcionaron mejor que las arquitecturas complejas. Se evaluó la utilidad práctica mediante métricas de trading.

- **Aplicaciones y desarrollos futuros estudiados:** Se determinó que las estrategias basadas únicamente en indicadores estadísticos tienen limitaciones importantes para generar beneficios consistentes. Se identificaron direcciones concretas para investigación futura en este campo.

5.2. Resultados Principales

Los resultados confirman la dificultad inherente de la predicción bursátil, pero también muestran algunos aspectos positivos. Los métodos más adecuados identificados son los modelos lineales y árboles de decisión simples, que superaron consistentemente a las arquitecturas más complejas. El modelo LINEAR fue el único que superó todas las líneas base aleatorias para el horizonte de 5 días, y junto con TREE alcanzaron precisiones direccionales cercanas al 60%. En casos específicos, como el modelo GRU aplicado a TSLA, se consiguió un retorno del 28% con alta tasa de éxito. Los modelos de aprendizaje profundo no mostraron ventajas consistentes sobre métodos más simples, contradiciendo las expectativas iniciales. XGBoost presentó el peor rendimiento general. Aunque ningún modelo superó consistentemente las líneas base en todas las métricas, los resultados muestran que cierta información predictiva existe en los datos históricos y que es posible obtener ventajas temporales en condiciones particulares.

5.3. Perspectivas Futuras

Los resultados de este trabajo abren varias direcciones para investigación futura:

- **Análisis de características avanzado:**
 - Implementar análisis de importancia de características para identificar qué indicadores contribuyen más a las predicciones exitosas
 - Estudiar el impacto específico de regímenes de volatilidad y económicos con períodos de datos más extensos que incluyan crisis financieras
- **Mejoras metodológicas:**
 - Desarrollar modelos orientados específicamente a decisiones de trading que integren costos de transacción y gestión de riesgo

- Implementar técnicas de ensemble que combinen las fortalezas de diferentes algoritmos
- Explorar ventanas temporales adaptativas que se ajusten a diferentes condiciones de mercado
- **Integración de datos adicionales:**
 - Incorporar análisis de sentimientos basado en noticias financieras y redes sociales
 - Incluir datos fundamental de empresas para enriquecer el análisis técnico
- **Aplicación práctica:**
 - Desarrollar sistemas de trading algorítmico que implementen las configuraciones más prometedoras identificadas en este estudio
 - Crear herramientas de apoyo a la decisión que combinen predicciones automáticas con análisis humano

6. REFERENCIAS

6.1. Bibliografía

- [1] Deep, A., Monico, C., Shirvani, A., Rachev, S., & Fabozzi, F. J. (2024). Assessing the Impact of Technical Indicators on Machine Learning Models for Stock Price Prediction. *arXiv preprint arXiv:2412.15448*.
- [2] Dunne, M. (2015). Stock market prediction. *University College Cork*.
- [3] Elliot, A., & Hsu, C. H. (2017). Time series prediction: predicting stock price. *arXiv preprint arXiv:1710.05751*.
- [4] Khan, W., Ghazanfar, M. A., Azam, M. A., Karami, A., Alyoubi, K. H., & Alfakeeh, A. S. (2022). Stock market prediction using machine learning classifiers and social media, news. *Journal of Ambient Intelligence and Humanized Computing*, 1-24.
- [5] Kumar, D., Sarangi, P. K., & Verma, R. (2022). A systematic review of stock market prediction using machine learning and statistical techniques. *Materials Today: Proceedings*, 49, 3187-3191.
- [6] Li, Y., & Pan, Y. (2022). A novel ensemble deep learning model for stock prediction based on stock prices and news. *International Journal of Data Science and Analytics*, 13(2), 139-149.
- [7] Lim, K. P., & Brooks, R. (2011). The evolution of stock market efficiency over time: A survey of the empirical literature. *Journal of economic surveys*, 25(1), 69-108.
- [8] Lin, X. (2023). The Limitations of the Efficient Market Hypothesis. *Highlights in Business, Economics and Management*, 20, 37-41.
- [9] Liu, L., & Si, Y. W. (2022). 1D convolutional neural networks for chart pattern classification in financial time series. *The Journal of Supercomputing*, 78(12), 14191-14214.
- [10] Malkiel, B. G. (2003). The efficient market hypothesis and its critics. *Journal of economic perspectives*, 17(1), 59-82.

- [11] Mnih, V., Kavukcuoglu, K., Silver, D., Graves, A., Antonoglou, I., Wierstra, D., & Riedmiller, M. (2013). Playing atari with deep reinforcement learning. *arXiv preprint arXiv:1312.5602*.
- [12] Moghaddam, A. H., Moghaddam, M. H., & Esfandyari, M. (2016). Stock market index prediction using artificial neural network. *Journal of Economics, Finance and Administrative Science*, 21(41), 89-93.
- [13] Ng, Y. (2019). Machine Learning Techniques applied to Stock Price Prediction. *Towards Data Science*, <https://towardsdatascience.com/machinelearning-techniques-applied-to-stock-priceprediction-6c1994da8001>.
- [14] Nti, I. K., Adekoya, A. F., & Weyori, B. A. (2020). A comprehensive evaluation of ensemble learning for stock-market prediction. *Journal of Big Data*, 7(1), 20.
- [15] Plaats, A., Kusters, W., & Preuss, M. (2020). Deep model-based reinforcement learning for high-dimensional problems, a survey. *arXiv preprint arXiv:2008.05598*.
- [16] Roondiwala, M., Patel, H., & Varma, S. (2017). Predicting stock prices using LSTM. *International Journal of Science and Research (IJSR)*, 6(4), 1754-1756.
- [17] Sylvester, J., & Chawla, N. V. (2005). Evolutionary ensembles: Combining learning agents using genetic algorithms. In *AAAI workshop on multiagent learning* (pp. 46-51).
- [18] Van Houdt, G., Mosquera, C., & Nápoles, G. (2020). A review on the long short-term memory model. *Artificial Intelligence Review*, 53(8), 5929-5955.
- [19] Vuong, P. H., Dat, T. T., Mai, T. K., & Uyen, P. H. (2022). Stock-price forecasting based on XGBoost and LSTM. *Computer Systems Science & Engineering*, 40(1).
- [20] Zhu, Y. (2020, October). Stock price prediction using the RNN model. In *Journal of Physics: Conference Series* (Vol. 1650, No. 3, p. 032103). IOP Publishing.
- [21] Zhu, Z., & He, K. (2022). Prediction of Amazon's stock price based on ARIMA, XGBoost, and LSTM Models. *Proceedings of Business and Economic Studies*, 5(5), 127-136.

6.2. Índice de figures

Fig. 1: Arquitectura del modelo de árbol de decisión (source).....	12
Fig. 2: Modelo LSTM (source [18])	15
Fig. 3: Arquitectura CNN para series temporales (source [9])	16
Fig. 4: Correlaciones de features con 5-d retornos	24
Fig. 5: Estructura final de datos	26
Fig. 6: Página principal del repositorio GitHub del proyecto	28
Fig. 7: Interfaz de línea de comandos (CLI) del sistema implementado	29
Fig. 8: Comparación RMSE para retornos a 1 día vs línea base Random Walk	33
Fig. 9: Comparación RMSE para retornos a 5 días vs línea base Random Walk.....	34
Fig. 10: Gráficos de dispersión predicciones vs valores reales - retornos 1 día	35
Fig. 11: Gráficos de dispersión predicciones vs valores reales - retornos 5 días.....	35
Fig. 12: Precisión direccional por modelo comparada con línea base aleatoria	36
Fig. 13: Mapa de calor: rendimiento de modelos de regresión a 1 día vs líneas base .	37
Fig. 14: Mapa de calor: rendimiento de modelos de regresión a 5 días vs líneas base	38
Fig. 15: Matrices de confusión para modelos de clasificación direccional	40
Fig. 16: Curvas ROC comparativas para predicción direccional.....	41
Fig. 17: Mapa de calor: métricas de clasificación por modelo	42
Fig. 18: Mapas de calor: rendimiento de trading por ticker (LINEAR)	43
Fig. 19: Mapas de calor: rendimiento de trading por ticker (TREE)	43
Fig. 20: Mapas de calor: rendimiento de trading por ticker (XGBOOST)	44
Fig. 21: Mapas de calor: rendimiento de trading por ticker (LSTM)	44
Fig. 22: Mapas de calor: rendimiento de trading por ticker (GRU).....	45
Fig. 23: Backtesting detallado del modelo GRU en TSLA (mejor caso)	46
Fig. 24: Backtesting detallado del modelo XGBoost en ^GSPC (peor caso)	47

7. ANEXOS

[a] Enlace al repositorio GitHub con el código del proyecto:

<https://github.com/PetkaKotletka/FinancialPrediction>

[b] Datos económicos (FRED - Federal Reserve Economic Data):

- VIX Volatility Index: <https://fred.stlouisfed.org/series/VIXCLS>
- Gross Domestic Product: <https://fred.stlouisfed.org/series/GDP>
- 10-Year Breakeven Inflation Rate: <https://fred.stlouisfed.org/series/T10YIE>